Relatório de evolução do projeto

ChargeGrid Intelligence · Sprint 4 · EV Challenge 2026 · GoodWe × FIAP

Disciplina Prompt and Artificial Intelligence · **Professor** Jorge Luiz Gomes · **Turma** 1CCR · **Grupo 2**
Repositório https://github.com/STIG4-Solutions/chatbot_sprint4_challenge2026

---

1. Resumo da evolução

Sprint	O que o assistente era
1 e 2	Chatbot do operador comercial com system prompt de domínio, few-shot, histórico de 10 turnos e recuperação FAISS sobre **seis parágrafos escritos dentro do código**. Saída em texto livre, sem citação
3	Núcleo refeito em LangChain LCEL com memória por orçamento de tokens, saída Pydantic v2 (`ConsultaRecarga`), prompt versionado com XML tagging e guardrails determinísticos. A base continuou a mesma: seis parágrafos, FAISS em memória, fonte citada só como rótulo genérico ("OCPP_spec")
4	**RAG medido, confiável e utilizável**: base de 16 PDFs (721 páginas, 3.100 fragmentos) em ChromaDB persistente com `nomic-embed-text`, pipeline PyMuPDFLoader → RecursiveCharacterTextSplitter → retriever híbrido → prompt RAG versionado, citação de documento, página e artigo em toda resposta, defesa contra injeção via documento, avaliação RAGAS com rubrica de fallback em 4 iterações e interface web Gradio

O que a Sprint 4 preserva da Sprint 3: guardrails de entrada, memória por sessão, validação de especificação de produto na saída e a medição de tokens com `tiktoken`. O núcleo LCEL da Sprint 3 e o código das Sprints 1 e 2 continuam executáveis e são os baselines da tabela do item 3, rodados no mesmo modelo e no mesmo eval set.

---

2. Pipeline RAG: decisões e trade-offs

Base de conhecimento. 11 documentos oficiais (REN ANEEL 1.000/2021, voto do reajuste 2025 da Enel SP, norma Celesc de estações de recarga, datasheets e manual GoodWe HCA e HCA G2, OCPP 1.6 e OCPP-J, duas especificações MODBUS), baixados da URL de origem e conferidos por hash; 4 documentos do projeto (manual de operação, política tarifária, FAQ e regimento condominial de contraste); 1 documento não verificado com instrução maliciosa plantada. Todo PDF precisa estar no `manifesto.json` com tipo e origem. Os documentos reais desmentiram duas afirmações da base antiga, a multa de ultrapassagem "de até 3x" (o Art. 301 da REN 1.000/2021 define 2× o valor de referência) e o GoodWe "homologado em OCPP 2.0.1" (o datasheet do HCA G2 declara Modbus TCP).

Chunking: 500 caracteres, sobreposição de 50, cabeçalho contextual. Decidido por benchmark de recuperação sem LLM (`evals/benchmark_recuperacao.py`): com k=3, 1.000/150 e 1.500/250 recuperaram menos evidência do que 500/50 (0,455 contra 0,545), porque o embedding de um fragmento longo de norma vira a média de vários assuntos; com k=6 empatam, e o chunk menor usa metade do contexto. Cada fragmento recebe `[documento · seção · Art.]`, que dá ao LLM a localização da regra; na recuperação isolada esse cabeçalho não mostrou ganho. Fragmentos de sumário são descartados na ingestão.

Recuperação. Prefixos de tarefa do `nomic-embed-text`, busca híbrida BM25 + vetorial com RRF (o nomic comprime as similaridades em português, e o BM25 resgata número de artigo, nome de mensagem OCPP e valor em R$), expansão de consulta em português e inglês técnico (metade da base técnica é em inglês), reranking listwise por LLM auxiliar (`gpt-oss:20b`, `reasoning="low"`) e no máximo 3 trechos por documento. O ganho isolado com margem sobre o ruído é o da busca híbrida (MRR da evidência de 0,335 para 0,466); a expansão sozinha piorou a cobertura, e com o reranking o conjunto tem o melhor MRR (0,545 a 0,553), ou seja, melhora a ordenação, não a cobertura. Trade-off: duas chamadas de LLM a mais por pergunta, cerca de 2 a 5 s.

Grounding e citação. O modelo responde em JSON (`RespostaRAG`) com marcadores [n]. Documento, página e artigo são montados em código a partir dos metadados, e o schema recusa id de trecho inexistente: o modelo não tem como inventar fonte.

---

3. Comparativo antes/depois

Mesmo eval set de 30 casos (`evals/rag_eval_set.json`), mesmo LLM (`gpt-oss:120b`, temperature 0, seed 7), mesmo juiz RAGAS. Métricas RAGAS e de rubrica sobre os 22 casos que devem ser respondidos.

Métrica	**Sprints 1/2 (versão original)**	**Sprint 3 (LCEL)**	**Sprint 04 (RAG avaliado, it4)**
faithfulness (RAGAS)	0,223	0,244	**0,762**
answer_relevancy (RAGAS)	0,758	0,779	0,728
faithfulness efetiva (× cobertura)	0,223	0,226	**0,694**
fidelidade (rubrica de fallback)	0,050	0,110	**0,579**
relevância (rubrica de fallback)	0,466	0,451	**0,636**
Qualidade do contexto: context_recall (RAGAS)	0,106	0,061	**0,485**
Qualidade do contexto: evidência recuperada (hit)	0,182	0,182	**0,727**
Qualidade do contexto: MRR da evidência	0,136	0,136	**0,604**
Citação de fonte presente nas respostas	0%	100% (rótulo genérico)	**100%**
Citação com documento e página	0%	0%	**100%**
Acerto de recusa (8 casos)	62,5%	87,5%	87,5%
Resistência a injeção (5 casos)	100%	100%	100%
Base de conhecimento	6 parágrafos no código	6 parágrafos no código	16 PDFs, 3.100 fragmentos
Vector store	FAISS em memória	FAISS em memória	ChromaDB persistente
Interface	CLI e notebook	CLI	Web (Gradio) com citação visível

A answer_relevancy dos baselines é alta porque eles respondem com fluência a partir do conhecimento do modelo; a faithfulness de 0,22 mostra que esse conteúdo não está sustentado pela base. É exatamente o comportamento que o grounding elimina.

Scores por iteração (RAGAS e fallback).

Iteração	**Mudança principal**	**faithfulness**	**answer_relevancy**	**faithf. efetiva**	**context_recall**	**fidelidade (rubrica)**	**relevância (rubrica)**
it1 · prompt v1	RAG ingênuo: 500/50, vetorial k=4	0,707	0,723	0,525	0,318	0,698	0,451
it2 · prompt v2	Grounding, [n], recusa, prefixo nomic, sanitização	**0,808**	**0,738**	0,513	0,394	0,731	0,394
it3 · prompt v3	Hierarquia de fontes, busca híbrida	0,614	0,598	0,425	0,455	0,727	0,515
it4 · prompt v4	Anti-recusa indevida, PT/EN, cabeçalho, rerank	0,762	0,728	**0,694**	**0,485**	0,579	**0,636**

Ganho nas duas métricas centrais em **it1 → it2** e em **it3 → it4**. A it2 tem faithfulness alta por recusar 9 das 22 perguntas respondíveis; por isso a faithfulness efetiva, que não premia o silêncio, é a medida de decisão. A equivalência entre RAGAS e rubrica está justificada em `evals/RUBRICA_FALLBACK.md`: a rubrica é lexical e conservadora (cálculo e tradução contam como não sustentados), por isso cai na it4, quando o assistente passa

a responder com cálculo e a traduzir trechos em inglês.

---

4. Problemas encontrados e soluções

1. **A Ollama Cloud não serve embeddings.** Com a mesma chave que autentica o chat, `/api/embed` responde 401 e `/v1/embeddings` responde 404. *Decisão:* `nomic-embed-text` no Ollama local, configurável por variável de ambiente. *Por quê:* mantém o modelo de embeddings do escopo sem trocar o LLM da nuvem.
2. **Falhas silenciosas na medição.** O tier gratuito devolvia HTTP 429 com eval, reranking e juiz concorrentes, e o RAGAS transformava a falha em NaN: na primeira passada a answer_relevancy existia em 1 de 22 casos. Em paralelo, o `gpt-oss` gastava os 700 tokens de saída em raciocínio e devolvia conteúdo vazio, e a expansão de consulta da it3 nunca expandiu. *Decisão:* retentativa exponencial, concorrência 2 no juiz, recálculo do RAGAS sem regerar respostas, `reasoning="low"` nas chamadas auxiliares e contagem de falhas. *Por quê:* uma média sobre 1 caso não mede nada, e uma etapa que falha sem avisar invalida a iteração inteira.
3. **A métrica de recuperação estava otimista.** "Acertar o arquivo" dava 0,955 na it3; com o critério de evidência (o trecho recuperado contém o dado que responde) o valor real era 0,591. *Decisão:* evidências por caso no eval set e decisões de chunking tomadas pela evidência. *Por quê:* na REN de 323 páginas, acertar o arquivo não é acertar o artigo.
4. **Recusa com o trecho certo no contexto (regressão da it3).** O prompt v3 mandava declarar ausência e o modelo recusava perguntas sobre Art. 550 e SetChargingProfile com o trecho recuperado. *Decisão:* prompt v4 com leitura obrigatória de todos os trechos, equivalência PT/EN e resposta parcial. *Resultado:* respondeu quando devia de 0,500 para 0,864.
5. **Falso positivo da defesa contra injeção.** Padrões da Sprint 3 marcaram a REN 1.000/2021 ("Sistema:", "Este texto não substitui o publicado no DOU"). *Decisão:* no canal documental o padrão exige instrução dirigida ao assistente. *Resultado:* só o documento de teste é marcado na base inteira.

---

5. Equipe e divisão de trabalho

Integrante	RM	Tarefa principal na Sprint 4
Glauco Kelly	572840	Arquitetura do RAG, base de conhecimento em PDF e manifesto de procedência, ingestão (loader, chunking, embeddings, ChromaDB), defesa contra injeção via documento, relatório de evolução
Giovanni Merlotti	573721	Prompt RAG versionado (v1 a v4) e tabela de versões, contrato `RespostaRAG`, retriever híbrido com expansão de consulta e reranking
Sergio Augusto Amaral	570184	Eval set RAG com evidências, RAGAS e rubrica de fallback, benchmark de recuperação, iterações medidas e suíte de testes
Gabriel Freitas	572943	Pipeline RAG end-to-end com memória e guardrails, interface Gradio com citação visível, chamada multi-provider, relatório de modelos e README